

数据集说明

1. 数据来源

本项目没有使用 LISA 或 TT100K 作为最终训练数据。最终数据来自：

```
raw/labelme_dataset.zip
```

压缩包内含用户使用 LabelMe 标注的 500 份 JSON 和对应道路图片，标注类型为 矩形检测框。图片中的交通标志存在树叶、树干、车辆、标志重叠和远距离小目标 等真实遮挡情况。

2. 类别

ID	LabelMe 原名	YOLO 类别名	中文含义	实例数
0	give way	give_way	减速让行	103
1	no stopping	no_stopping	禁止停车	102
2	parking place	parking_place	停车位	103
3	pedestrian crossing	pedestrian_crossing	人行横道	106
4	tow truck	tow_truck	清障车相关标志	101

类别数为 5，满足课程 “至少 5 类交通标志” 的要求。

3. 转换结果

转换脚本：

```
python scripts/prepare_labelme_dataset.py \  
--source raw/labelme_dataset.zip \  
--output dataset \  
--overwrite
```

脚本完成以下操作：

- 1. 直接读取 ZIP 内的 LabelMe JSON 和图片，不要求手动解压。
- 2. 将矩形框转换为 YOLO 归一化格式。
- 3. 按五个类别目录进行 70%/15%/15% 分层划分。
- 4. 使用图片内容哈希检查重复文件。
- 5. 将浮点误差造成的边界轻微越界裁剪到合法范围。
- 6. 生成 data.yaml 、 metadata.csv 和 summary.yaml 。

原始 500 张图片中有 1 张内容完全重复，因此保留 499 张唯一图片。最终统计：

划分	图片数	检测框数
train	349	360
val	75	77
test	75	78
合计	499	515

YOLO 标签格式：

```
class_id x_center y_center width height
```

全部坐标均归一化到 [0, 1] 。

4. 数据目录

```
dataset/  
├─ images/  
│   ├── train/  
│   ├── val/  
│   └─ test/  
├─ labels/  
│   ├── train/  
│   ├── val/  
│   └─ test/  
├─ data.yaml  
├─ metadata.csv  
└─ summary.yaml
```

数据校验命令：

```
python scripts/validate_dataset.py \  
  --data dataset/data.yaml \  
  --metadata dataset/metadata.csv \  
  --out results/dataset_validation.yaml
```

当前校验结果为 `valid: true`，没有缺失标签、孤立标签、非法类别或越界框。

5. 遮挡增强训练集

`scripts/augment_occlusion.py` 只增强训练集，在目标框内部模拟：

- foliage：树叶色块；
- branch：树枝线条；
- vehicle：车辆颜色遮挡块。

遮挡比例定义：

等级	在目标框内追加的遮挡比例
light	10%-20%
medium	20%-45%
heavy	45%-65%

生成命令：

```
python scripts/augment_occlusion.py \  
  --src dataset \  
  --dst dataset_occlusion_aug \  
  --copies 1 \  
  --seed 42 \  
  --overwrite
```

生成 349 张增强训练图，其中 light 98 张、medium 126 张、heavy 125 张。原图和增强图合计 698 张；验证集与测试集保持原样，保证模型对比公平。

6. 条件测试集

`dataset_conditions` 由 75 张真实测试图片生成，每张包含 7 个版本：

组别	数量	是否合成	处理
real	75	否	原始真实遮挡图
day	75	是	CLAHE 与轻微亮度校正
night	75	是	HSV 亮度缩放至 32%
blur	75	是	11×11 高斯模糊
light	75	是	追加轻度目标遮挡
medium	75	是	追加中度目标遮挡
heavy	75	是	追加重度目标遮挡

总计 525 张图片、546 个框。源测试图与训练图互斥，生成版本只用于评估，没有进入训练过程。

7. 遮挡分级解释

原始 LabelMe 标注只提供检测框，没有遮挡区域掩码，因此无法从原数据精确计算 真实遮挡百分比。本项目将原始图统一标记为 `real_occluded`，而 light、medium、heavy 指在真实遮挡基础上追加的合成遮挡强度。

该设计可以公平比较模型对逐渐缺失目标信息的鲁棒性，但不能替代人工标注的 真实无遮挡/轻度/中度/重度基准。报告和 PPT 中均明确披露这一限制。